

MapReduce (MR) и распределенные консольные утилиты

Драль Алексей, study@bigdatateam.org CEO at BigData Team, https://bigdatateam.org https://www.facebook.com/bigdatateam



MapReduce: Simplified Data Processing on Large Clusters

Jeffrey Dean and Sanjay Ghemawat

jeff@google.com, sanjay@google.com

Google, Inc.

Abstract

MapReduce is a programming model and an associated implementation for processing and generating large data sets. Users specify a *map* function that processes a key/value pair to generate a set of intermediate key/value pairs, and a *reduce* function that merges all intermediate values associated with the same intermediate key. Many real world tasks are expressible in this model, as shown

given day, etc. Most such computations are conceptually straightforward. However, the input data is usually large and the computations have to be distributed across hundreds or thousands of machines in order to finish in a reasonable amount of time. The issues of how to parallelize the computation, distribute the data, and handle failures conspire to obscure the original simple computation with large amounts of complex code to deal with these issues.

MapReduce: Simplified Data Processing on Large Clusters, Symposium on Operating Systems Design and Implementation (OSDI, 2004)



MapReduce: Simplified Data Processing on Large Clusters

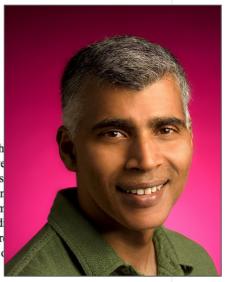
Jeffrey Dean and Sanjay Ghemawat jeff@google.com, sanjay@google.com

Google, Inc.

Abstract

MapReduce is a programming model and an associated implementation for processing and generating large data sets. Users specify a *map* function that processes a key/value pair to generate a set of intermediate key/value pairs, and a *reduce* function that merges all intermediate values associated with the same intermediate key. Many real world tasks are expressible in this model, as shown

given day, etc. Most such ally straightforward. Howe large and the computations hundreds or thousands of r a reasonable amount of tin allelize the computation, d failures conspire to obscur tation with large amounts of these issues.



MapReduce: Simplified Data Processing on Large Clusters, Symposium on Operating Systems Design and Implementation (OSDI, 2004)



MapReduce: Simplified Data Processing on Large Clusters

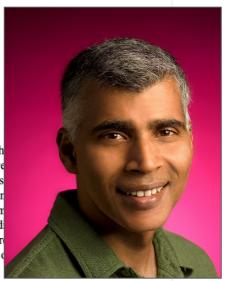


Jeffrey Dean and Sanjay Ghemawat jeff@google.com, sanjay@google.com

Google, Inc.

ract

ming model and an associcessing and generating large ap function that processes a et of intermediate key/value that merges all intermediate me intermediate key. Many ble in this model, as shown given day, etc. Most such ally straightforward. Howe large and the computations hundreds or thousands of r a reasonable amount of tim allelize the computation, difailures conspire to obscurtation with large amounts of these issues.



MapReduce: Simplified Data Processing on Large Clusters, Symposium on Operating Systems Design and Implementation (OSDI, 2004)



Джефф Дин (Jeffrey Dean)





Когда Jeff Dean разрабатывает ПО, он сначала создает бинарник, а потом пишет исходный код как документацию.





- Когда Jeff Dean разрабатывает ПО, он сначала создает бинарник, а потом пишет исходный код как документацию.
- Однажды Jeff Dean не прошел тест Тьюринга, потому что корректно посчитал 203 число Фибоначчи менее чем за 1 секунду.





- Когда Jeff Dean разрабатывает ПО, он сначала создает бинарник, а потом пишет исходный код как документацию.
- Однажды Jeff Dean не прошел тест Тьюринга, потому что корректно посчитал 203 число Фибоначчи менее чем за 1 секунду.
- Скорость, с которой Jeff Dean разрабатывает ПО выросла в 40 раз в конце 2000, когда он обновил свою клавиатуру до USB2.0.





- Когда Jeff Dean разрабатывает ПО, он сначала создает бинарник, а потом пишет исходный код как документацию.
- Однажды Jeff Dean не прошел тест Тьюринга, потому что корректно посчитал 203 число Фибоначчи менее чем за 1 секунду.
- Скорость, с которой Jeff Dean разрабатывает ПО выросла в 40 раз в конце 2000, когда он обновил свою клавиатуру до USB2.0.
- ▶ Вы используете только 10% мозга. Остальные 90% используются под запуск MapReduce задач Джефа.



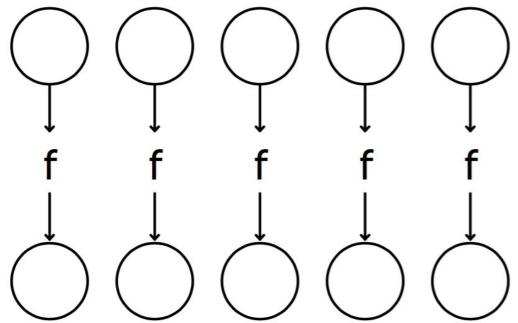


- Когда Jeff Dean разрабатывает ПО, он сначала создает бинарник, а потом пишет исходный код как документацию.
- Однажды Jeff Dean не прошел тест Тьюринга, потому что корректно посчитал 203 число Фибоначчи менее чем за 1 секунду.
- Скорость, с которой Jeff Dean разрабатывает ПО выросла в 40 раз в конце 2000, когда он обновил свою клавиатуру до USB2.0.
- ▶ Вы используете только 10% мозга. Остальные 90% используются под запуск MapReduce задач Джефа.



https://www.guora.com/What-are-all-the-Jeff-Dean-facts

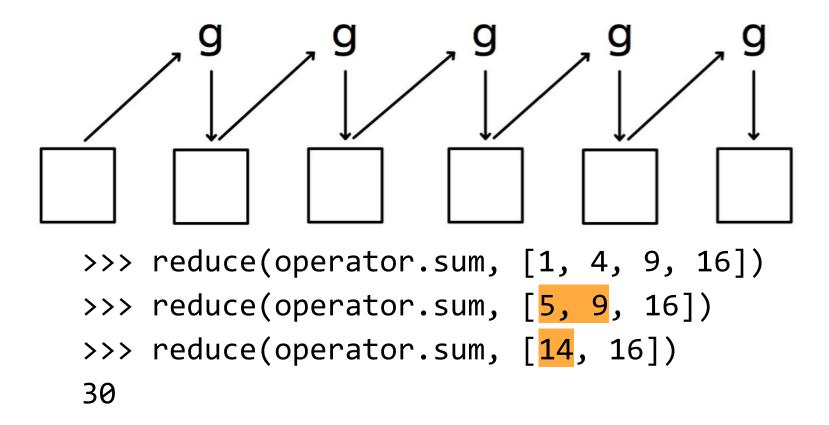




>>> map(lambda x: x*x, [1,2,3,4])
[1,4,9,16]

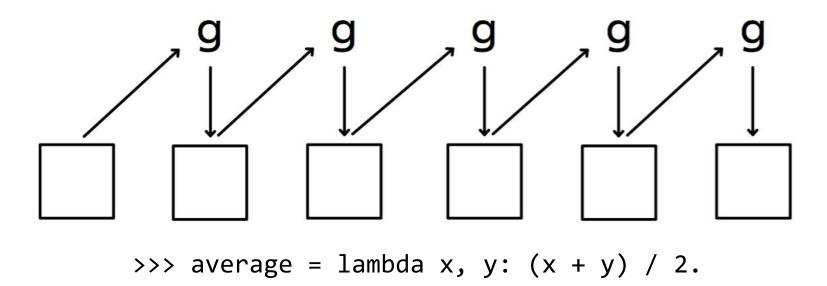


Fold / Reduce / Aggregate

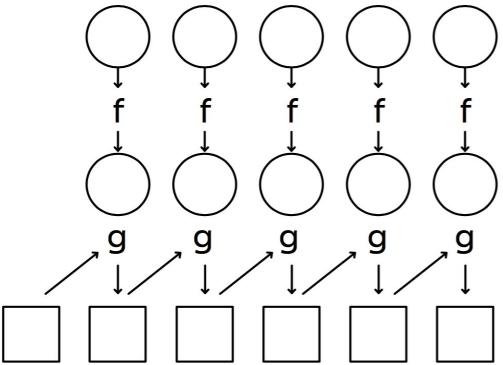




Fold / Reduce / Aggregate







>>> reduce(operator.add, map(lambda x: x*x, [1, 2, 3, 4])) 30



распределенные консольные утилиты

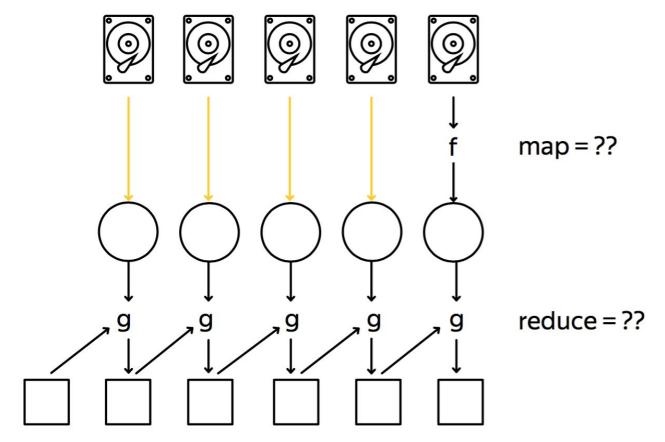




```
$ grep <pattern> <file>
$ grep "hadoop" A.txt
Repository git-wip-us.apache.org/repos/asf/hadoop.git
Website hadoop.apache.org
$ grep -i "hadoop" A.txt
Apache Hadoop
Apache Hadoop
Hadoop Logo
Repository git-wip-us.apache.org/repos/asf/hadoop.git
Website hadoop.apache.org
Apache Hadoop (/hə`du:p/) is
 man grep
```

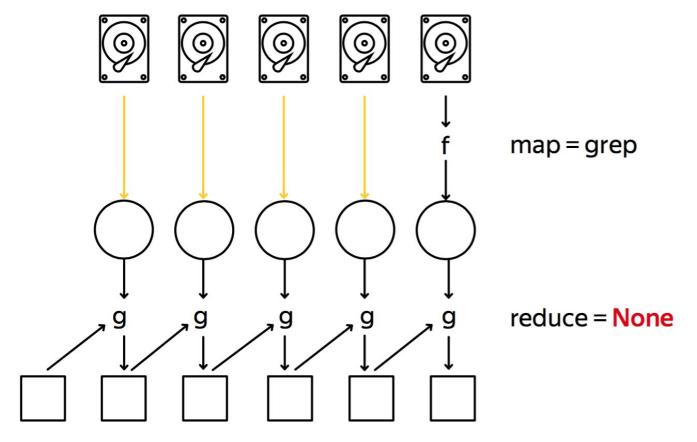


Distributed Shell: grep





Distributed Shell: grep





- \$ head <file>
- \$ head A.txt

Apache Hadoop

From Wikipedia, the free encyclopedia

[hide]This article has multiple issues. Please help improve it or discuss these issues on the talk page. (Learn how and when to remove these template messages)

This article contains content that is written like an advertisement. (October 2013)

This article appears to contain a large number of buzzwords. (October 2013)

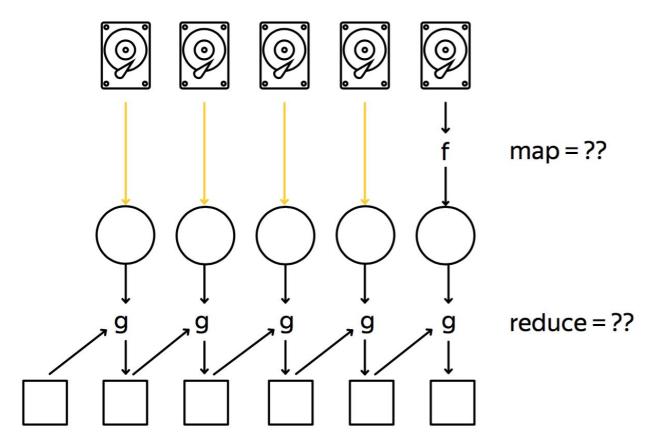
This article may be too technical for most readers to understand. (May 2017)

Apache Hadoop

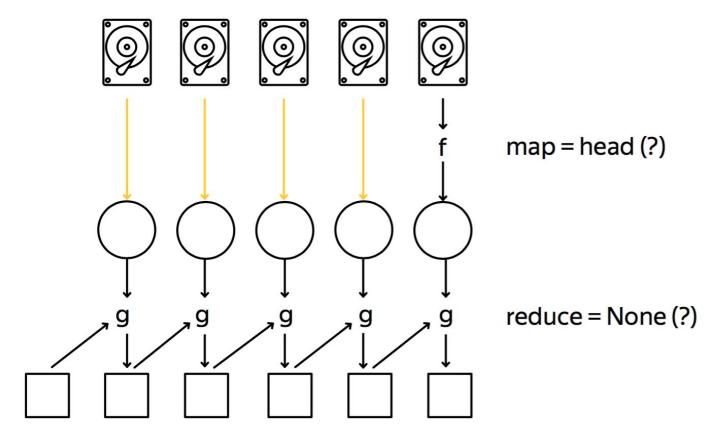
Hadoop Logo

Developer(s) Apache Software Foundation









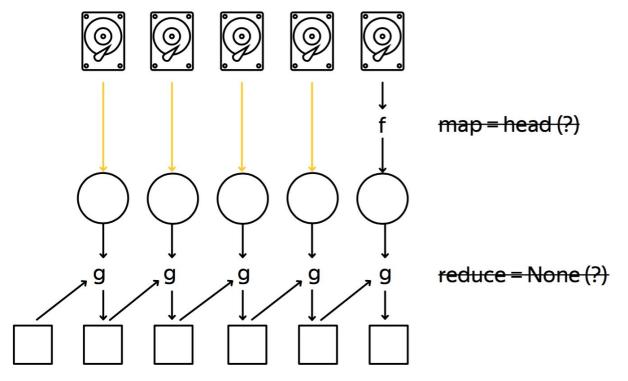




map = head (?)

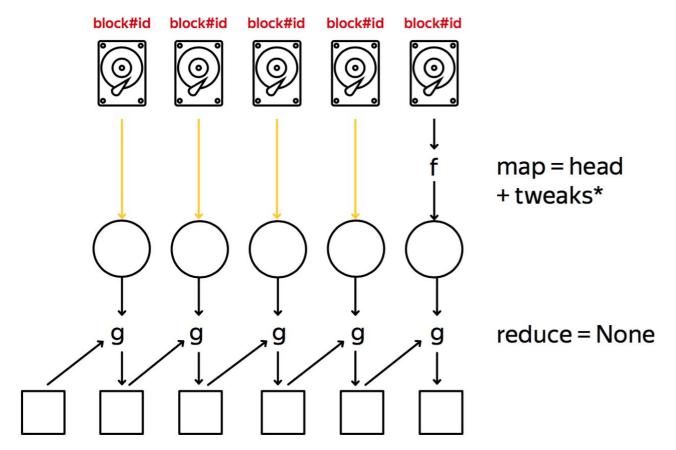
reduce = None (?)





HDFS v.2*: hdfs dfs -text distributed_A.txt | head HDFS v.3+: hdfs dfs -head distributed_A.txt

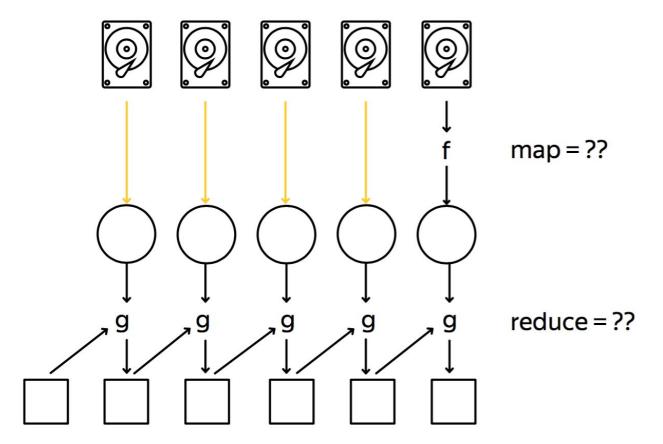




```
$ wc <file>
$ wc A.txt
269 4319 28001 A.txt
```

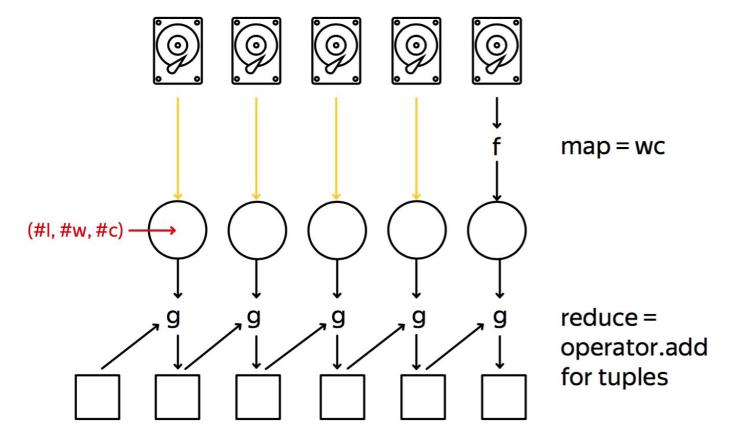


Distributed Shell: wc





Distributed Shell: wc











Теперь вы:

Знаете пионеров отрасли в лицо



Теперь вы:

- Знаете пионеров отрасли в лицо
- Знакомы с парадигмой MapReduce и можете объяснить как это связано с функциональной парадигмой



Теперь вы:

- Знаете пионеров отрасли в лицо
- Знакомы с парадигмой MapReduce и можете объяснить как это связано с функциональной парадигмой
- Умеете делать grep, head, wc c помощью Hadoop MapReduce и HDFS